

Phase 1 — Sprint Qualification

Résumé du travail réalisé Groupe 14

Le défi : comprendre ce qui se passe au Bénin grâce aux données mondiales

Étape 1 : Récupérer les données sans se perdre

La première mission, c'était de collecter les données. Ça paraît simple, mais GDELT est énorme — des dizaines de gigaoctets par mois. L'équipe a donc mis en place un pipeline intelligent avec trois niveaux de secours : d'abord on regarde si les données sont déjà en cache local, sinon on interroge BigQuery (Google Cloud), et en dernier recours on télécharge directement depuis GDELT via HTTP. Pour éviter de griller le quota de données gratuit, chaque requête est d'abord estimée en "dry run" avant d'être lancée pour de vrai. Résultat : un système robuste, économe, et qui tourne même sans connexion cloud.

Étape 2 : Explorer et comprendre les données

Une fois les données récupérées, l'équipe les a passées au microscope. On a regardé deux grandes tables GDELT : les événements (qui a fait quoi, où, quand) et les données GKG qui donnent le ton émotionnel des articles de presse. Des indicateurs clés ont été analysés : le score de Goldstein (qui mesure l'impact sur la stabilité d'un pays), le ton moyen des articles, le nombre de mentions médiatiques. Cette phase d'exploration a permis de vraiment comprendre la structure des données avant de modéliser quoi que ce soit.

Étape 3 : Entraîner des modèles de machine learning

C'est là que ça devient sérieux. L'équipe a appliqué plusieurs techniques d'apprentissage automatique sur les données nettoyées. Un algorithme de clustering (K-Means) a été utilisé pour regrouper les événements en catégories homogènes. Ensuite, deux modèles de classification — Random Forest et XGBoost — ont été entraînés pour détecter les événements conflictuels. Les résultats ont été validés rigoureusement avec des métriques standards (matrice de confusion, scores de performance). Les modèles entraînés ont été sauvegardés pour être réutilisés dans la dernière étape.

Étape 4 : Prédire et anticiper les risques

La dernière étape, la plus ambitieuse, visait à prédire l'avenir. À partir des données historiques, l'équipe a construit un système de prédiction de risques à trois horizons de temps : 1 semaine, 4 semaines et 12 semaines. L'outil Prophet (de Meta) a été utilisé pour modéliser les séries temporelles. Un score de risque composite a été calculé pour chaque période, avec un système d'alerte précoce. Même une simulation de scénarios a été intégrée pour répondre à la question : "et si les tensions s'intensifiaient ?"

Ce qu'on retient

En partant de zéro avec des données publiques massives, l'équipe a réussi à construire un pipeline complet — de la collecte à la prédiction — entièrement orienté vers un cas d'usage concret : mieux comprendre la situation socio-politique au Bénin. Le projet montre qu'avec de la rigueur technique et une bonne organisation du travail, il est possible de transformer des millions de lignes de données brutes en signaux d'alerte exploitables. L'IA (Claude d'Anthropic) a été utilisée en soutien tout au long du projet, conformément aux règles du challenge.